GPT-2における有理活性化関数の有効性検証

GPT-2の基本構造を踏襲した小規模モデルでの比較

鴛尾 直樹 (東京都立大学大学院 M2, okinaoki24@gmail.com)

Q. 活性化関数の「形」も学習すると、文章の予測は良くなるのか？

A. 今回の実験条件では改善は確認できなかった

1. 背景・研究の問い

先行研究：Fang et al. [2]
- BERT型モデルの内部の「**活性化関数**」を，
- 固定形の**GELU**から「**係数を学習する有理関数**」**(有理活性化関数[1])**に置き換えた結果，
- 予測精度の改善を実証．

BERT型モデル:
「文中の隠した語」を当てるLLM
(例: 感情分析・レビュー分析)

本研究
- GPT型モデルの内部の活性化関数を，
- GELUから**有理活性化関数**に置き換え，
- 予測精度の変化を検証．

GPT型モデル:
「次の語」を予測するLLM
(例: ChatGPT等の文章生成AI)

【メインテーマ】有理活性化は，次トークン予測の性能を改善するか？

【サブテーマ 】分母の平滑化，初期化の近似区間 (後述)は結果に影響するか？

2. 有理活性化関数の設計

【関数形】

$F(x) = P(x)/Q(x)$

分子: $P(x) = a_0 + a_1x + a_2x^2 + a_3x^3 + a_4x^4 + a_5x^5$

分母 : $Q(x)$ として以下の2パターンを採用

多項式 P は5次，
多項式 Aは4次で次数を固定

4次多項式 $A(x) = b_1x + b_2x^2 + b_3x^3 + b_4x^4$ に対し

学習係数は各層10個，6層
→全体でパラメータ数 + 60

- 標準分母: $Q(x) = 1 + |A(x)|$
  実軸上の極を避ける手段として絶対値を用いる (先行研究 [1,2] 準拠)
- 平滑分母: $Q(x) = 1 + \sqrt{\epsilon + A(x)^2}\,, \epsilon = 10^{-3}$
  分母を滑らかにすることで，学習の安定化を期待 (【サブテーマ】の検証)

【初期化】
- パラメータ $\{a_i\}_{0\le i\le 5}\,, \{b_i\}_{1\le i\le 4}$の初期化は，GELUへの近似で行う．
- その際の近似区間は，先行研究[1]の[-3, 3] を基準とし，[-6, 6]に拡張した場合と比較 (【サブテーマ】の検証)

3. 実験設定

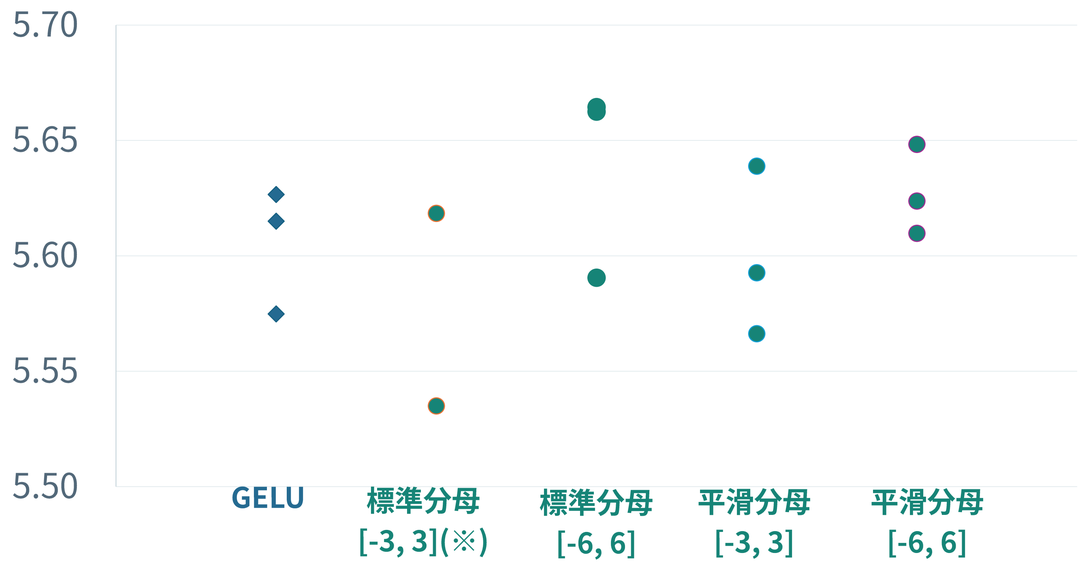
モデル	GPT-2系の小規模モデルを独自実装．6層・幅384・6ヘッド，Attention・FFNの線形層はバイアス無し．
課題	モデルを一から事前学習し，次のトークンを予測
規模	6層，隠れ層の幅=384，パラメータ数=13,870,848
データ	TinyStories (英語の短い物語)， 文脈長 256トークン
比較条件	GELU， 有理活性化関数 4条件 [分母2種類 × 初期化区間 2種類(※1)]
学習量 ・反復	学習完走時 12,200ステップ(※2)，約1億トークン． 各条件で乱数シードを変えて3回実施．
評価	検証データのPPL (perplexity)．小さいほど予測性能が良い．

※ 1. 有理関数の初期係数はGELUへの近似で作成し，近似区間を [-3, 3]と[-6, 6] で比較した．
※ 2. 「学習完走」: 予定の12,200ステップまで途中停止せずに学習を完遂すること．

AdamWを使用．本体の最大学習率は10^{-3}，係数はその約7.14倍．
全条件に勾配クリッピング (閾値 1) を適用．
学習率の探索はGELUのみで実施し，選んだ本体学習率を全条件に使用．

4. 主結果：GELUを上回る結果は得られず

各活性化関数について，事前学習した結果得られた**PPLの値 (小さいほど高精度)**をプロット．
各点は，乱数シードを変えた各試行の学習完走時のPPLを示す．

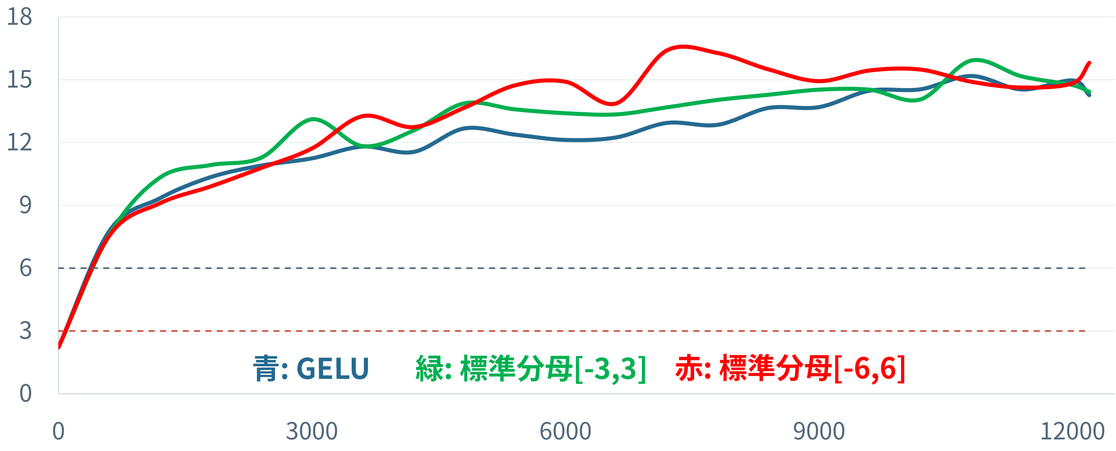


※ 標準分母 [-3, 3] において，1つの乱数で勾配ノルム急増による事前停止基準に到達，2データのみ．

完走3回が揃った有理条件では，PPLの最小〜最大の範囲がGELUと重なった．事前に定めた判定基準では，GELUに対する性能改善は確認できなかった

5. 補足解析: 学習中の入力は近似区間に収まるか

GELU・標準分母2条件の乱数シードは0であり，各評価時の1バッチについて，
活性化関数へ入る値の全層最大絶対値を表示．



有理関数を初期化する近似区間に対し，実際の入力がどこまで広がるかを調べた．

観測した入力の最大絶対値は，学習初期の約2.2から最終的に約14〜16へ増加し，両方の近似区間を超えた．

ただし，区間外の入力が予測性能に与えた影響は未特定．

6. 結論・今後の課題

【結論】

小規模GPT型モデルを一から学習した今回の設定では，有理活性化によるGELUからの性能改善は確認できなかった．分母の平滑化・初期化区間の拡張による一貫した改善も確認できなかった．

【限界】

モデル規模・データ・学習目的・安定化法が先行研究と異なるため，先行研究との違いを特定の原因に帰することはできない．今回の結果をGPT型モデル全般へ一般化することもできない．

【今後の課題】

通常の重みと有理係数の勾配を分けて記録し，実際の更新量や学習後の関数形状を調べることで，性能差や停止の原因を切り分ける．

7. 参考文献

[1] Molina et al., Padé Activation Units, ICLR 2020.
[2] Fang et al., Transformers with Learnable Activation Functions, EACL 2023.
[3] Yang & Wang, Kolmogorov–Arnold Transformer.
[4] Boullé et al., Rational Neural Networks, NeurIPS 2020.